Relatório Técnico — Tech Challenge Fase 1

27 de out. de 2026

Pós-Tech IA para Devs (FIAP) · Fase 1

Repositório Git: github.com/gabrielrb/tech-challenge-fase1

Resumo

Este trabalho apresenta dois modelos de apoio à triagem médica. Na Parte A, um Random Forest classifica nódulos da mama como malignos ou benignos a partir de 30 medidas das células. Na Parte B, comparamos duas redes neurais convolucionais e um modelo clássico para detectar pneumonia em radiografias de tórax. Nas duas partes, a métrica principal é o recall da classe doente, porque o erro mais grave é deixar um doente sem diagnóstico.

Parte	Problema	Modelo final	Recall da classe doente (teste)	Outras métricas (teste)
A	câncer de mama (tabela)	Random Forest	0,93 (39 de 42 cânceres)	acurácia 0,97 · precisão 1,00 · F1 0,96 · AUC 0,994
B	pneumonia (raio-X)	CNN 2	0,99 (385 de 390 pneumonias)	recall de NORMAL 0,41 · AUC 0,896

1. Problema e métrica

1.1 O problema

Um hospital universitário quer um sistema de apoio ao diagnóstico para acelerar a triagem de exames. Nesta fase, o sistema classifica cada exame como "doente" ou "não doente". Ele aponta os casos suspeitos para o médico olhar primeiro, mas a decisão final é sempre do médico. Os dois problemas são de classificação supervisionada: cada exame já tem a resposta certa, e essa resposta é uma categoria.

1.2 Métrica principal

O erro mais grave é o falso negativo: dizer que um doente está saudável, o que atrasa o tratamento. Por isso, a métrica principal das duas partes é o recall da classe doente, que mostra quantos dos doentes reais o modelo encontra. Também olhamos a precisão (dos exames que o modelo chamou de doentes, quantos eram mesmo doentes), o F1 (uma nota que junta recall e precisão) e a acurácia (o total de acertos). A acurácia sozinha engana quando as classes são desiguais. A AUC resume a curva ROC: vai de 0,5 (um chute) a 1,0 (separação perfeita).

2. Parte A: câncer de mama (dados em tabela)

2.1 Base de dados: Breast Cancer Wisconsin (Diagnostic)

A base vem da UCI e foi baixada do Kaggle. Ela tem 569 pacientes e 30 medidas numéricas do núcleo das células, tiradas de imagens digitalizadas de punção por agulha fina. São 10 medidas, como raio, textura, área e concavidade, cada uma em três versões: média, erro padrão e pior valor. O alvo é a coluna `diagnosis`, com 212 tumores malignos (37%) e 357 benignos (63%).

2.2 Pré-processamento

Exploração dos dados. Começamos com estatísticas descritivas, a contagem das classes e gráficos de distribuição por classe. Quatro achados guiaram o pré-processamento:

1. As classes são desiguais (63% benignos e 37% malignos), por isso a divisão dos dados foi estratificada.
2. As medidas separam bem as classes: os tumores malignos têm raio e área maiores e mais pontos côncavos (tabela abaixo).
3. As colunas têm escalas muito diferentes: `area_mean` chega a 2.501, enquanto `smoothness_mean` fica perto de 0,1. Por isso, os modelos que usam distância (KNN e SVM) recebem dados padronizados.
4. Há valores extremos, mas eles batem com o raio e o perímetro do mesmo paciente, então não parecem erro de digitação. Não os removemos, porque isso apagaria justamente os casos malignos mais claros.

Médias por classe. A tabela compara quatro medidas entre benignos e malignos.

Medida (média)	Benigno	Maligno
`radius_mean` (raio)	12,15	17,46
`area_mean` (área)	462,79	978,38
`concave points_mean` (pontos côncavos)	0,03	0,09
`texture_mean` (textura)	17,91	21,60

Raio, área e pontos côncavos mudam muito entre as classes. A textura muda menos, e o histograma mostra muita sobreposição entre benignos e malignos.

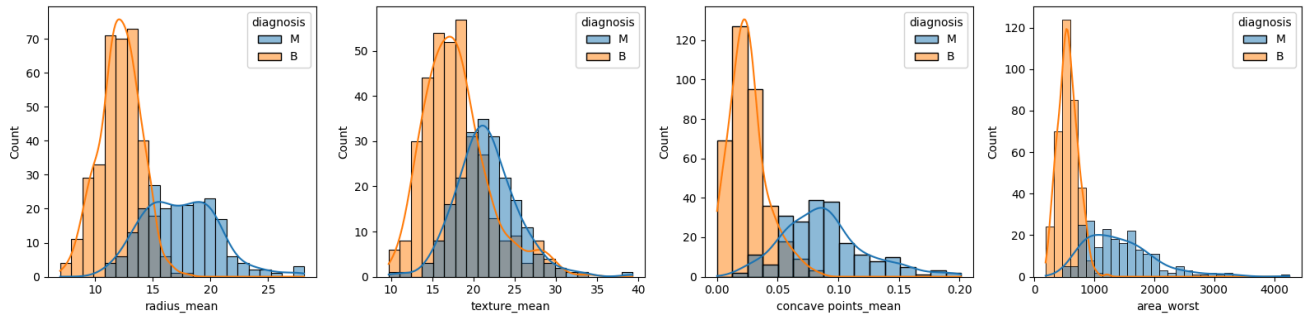


Figura 1 — Histogramas de quatro medidas, por classe (M = maligno, B = benigno)

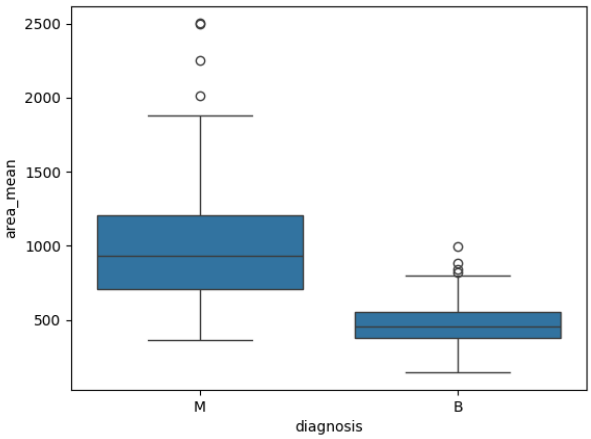


Figura 2 — Boxplot da área média por classe

Limpeza e conversão. Fora a coluna Unnamed: 32, que está toda vazia, a base não tem valores ausentes nem pacientes repetidos. A tabela abaixo resume as decisões de limpeza. Duas delas merecem explicação. O alvo foi convertido com o LabelEncoder (benigno = 0 e maligno = 1): com só duas categorias, isso não cria uma ordem falsa, e o recall e o F1 passam a ser calculados para a classe maligna. Já a padronização (StandardScaler) ficou dentro de um Pipeline, para aprender a média e o desvio só com os dados de treino e evitar vazamento de dados. O One-Hot Encoding não foi necessário, porque as 30 colunas de entrada já são numéricas.

Decisão	Motivo
`id` removida	é só um código e não ajuda a prever
`Unnamed: 32` removida	a coluna está vazia
nenhuma linha removida	não há nulos nem duplicados nas medidas
zeros mantidos nas colunas de `concavity` e `concave points` (os mesmos 13 pacientes, todos benignos, nas 6 colunas de concavidade)	são valores reais, de células sem concavidade
alvo com LabelEncoder (maligno = 1)	o recall e o F1 ficam na classe maligna
padronização dentro do Pipeline	o `fit` usa só o treino

Análise de correlação. As colunas mais ligadas ao câncer são `concave points_worst` (0,79), seguida de `perimeter_worst`, `concave points_mean` e `radius_worst` (0,78 cada). Isso mostra uma associação, não uma causa: tumores malignos tendem a ter células maiores e com mais concavidades. Outras colunas quase não têm relação com o diagnóstico, como `fractal_dimension_mean` (−0,01).

As colunas também repetem informação entre si: 21 pares têm correlação acima de 0,9. Por exemplo, `radius_mean` e `perimeter_mean` têm correlação de 0,998, porque raio, perímetro e área medem o mesmo tamanho da célula. Essa repetição motivou o teste com PCA (seção 2.3).

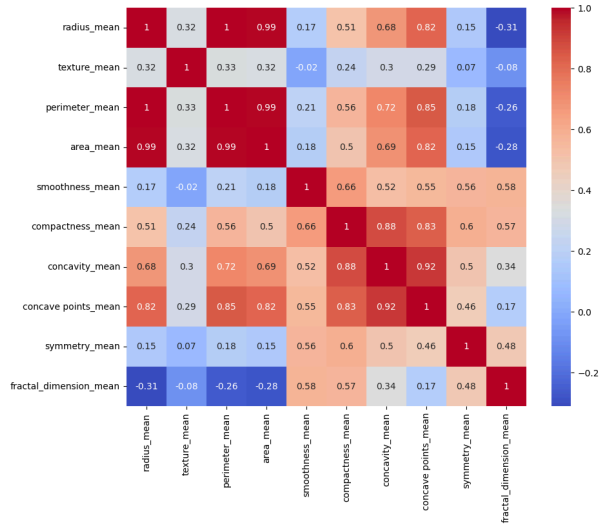


Figura 3 — Correlação entre as 10 colunas "_mean"

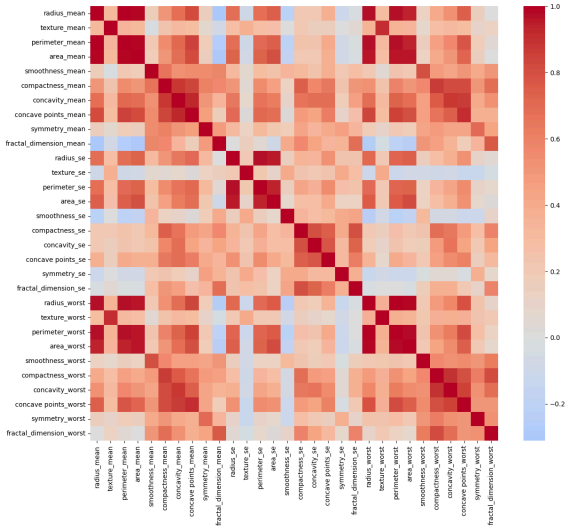


Figura 4 — Correlação entre as 30 colunas

Treino, validação e teste. Separamos 20% dos pacientes (114) para o teste, que ficou guardado até a avaliação final, depois de todas as escolhas. Os outros 455 (80%) formam o treino. A validação foi feita dentro do treino, com validação cruzada em 5 partes (KFold): cada parte serve de validação uma vez, e a nota final é a média das 5 rodadas. A separação entre treino e teste foi estratificada e usou `random_state=42`. As 5 partes do KFold foram sorteadas sem estratificar, então a proporção de malignos varia um pouco entre elas (de 33% a 43%). Preferimos a validação cruzada a um bloco fixo de validação porque, com 569 pacientes, esse bloco seria pequeno e a nota dependeria da sorte. Todos os números da Parte A foram gerados com o scikit-learn 1.6.1; em outra versão, o Random Forest pode mudar um pouco.

2.3 Modelos usados e por quê

Modelos testados. Testamos quatro modelos de classificação, cada um com uma forma diferente de decidir:

Modelo	Como decide	Por que testar
KNN	pelos pacientes mais parecidos	simples; serve de base de comparação
SVM	pela fronteira com a maior margem entre as classes	bom para bases pequenas com muitas colunas
Árvore de Decisão	por regras "se / senão"	fácil de explicar ao médico
Random Forest	pelo voto de muitas árvores	menos overfitting que uma árvore só

Comparação na validação. A tabela mostra a média das 5 rodadas do KFold.

Modelo	Recall	Desvio do recall	F1	Acurácia
SVM	0,942	0,035	0,951	0,963
Random Forest	0,933	0,051	0,943	0,958
Árvore	0,922	0,045	0,918	0,938
KNN	0,911	0,041	0,944	0,960

O SVM e o Random Forest ficaram à frente, e a diferença entre eles (0,009) é menor que a variação entre as rodadas: um empate técnico. Por isso, os dois seguiram para o ajuste. O KNN mostra por que a acurácia sozinha não basta neste problema: ele teve uma das melhores acurácias (0,960), mas o pior recall (0,911).

Teste com PCA. Por causa dos 21 pares de colunas muito correlacionadas, testamos também o PCA. Ele reduziu as 30 colunas a 10 componentes, guardando 95% da informação, e o recall do SVM não mudou (0,942). Como o resultado foi o mesmo, mantivemos as 30 colunas originais, que são mais fáceis de interpretar.

Ajuste dos hiperparâmetros. O SVM e o Random Forest foram ajustados com o GridSearchCV, que testa todas as combinações de hiperparâmetros com validação cruzada e fica com a de maior recall. No Random Forest, as profundidades máximas sem limite e 10 empataram no recall, e a grade ficou com a primeira, sem limite. A precisão também foi medida, como conferência: 0,965 no SVM e 0,957 no Random Forest. Ou seja, nenhum dos dois ganhou recall chamando quase todos de malignos.

Modelo	Melhor combinação	Recall na validação	Desvio	Treinos feitos
SVM	C = 10, kernel rbf, class_weight balanced	0,959	0,015	16 combinações × 5 = 80
Random Forest	300 árvores, sem limite de profundidade, class_weight None (pesos iguais)	0,938	0,042	12 combinações × 5 = 60

Modelo final: Random Forest. O SVM teve recall um pouco maior (0,959 contra 0,938) e variou menos entre as rodadas (0,015 contra 0,042). A diferença média, porém, é de só 0,021: menos de 1 câncer por rodada, já que cada parte da validação tem cerca de 34 malignos. Escolhemos o Random Forest porque ele mostra de forma direta quais colunas pesam na decisão, o que ajuda o médico a confiar no modelo. Sabemos que, com isso, abrimos mão de um pouco de recall na validação. A escolha foi feita antes de olhar o teste.

Não incluímos a regressão logística, citada no enunciado como exemplo. O SVM com kernel linear, testado no GridSearch, já representa um modelo linear, e os quatro modelos atendem ao pedido de duas ou mais técnicas.

2.4 Resultados e interpretação

Resultado no teste. No teste, com 114 pacientes (42 deles com câncer), o Random Forest acertou 111 casos, uma acurácia de 0,97. Ele encontrou 39 dos 42 cânceres (recall de 0,93) e não deu nenhum alarme falso (precisão de 1,00). O F1 foi de 0,96, e a área sob a curva ROC (AUC), de 0,994: o modelo separa as classes quase perfeitamente.

Real \ Previsto	Benigno	Maligno
Benigno (72)	72 acertos	0 alarmes falsos
Maligno (42)	3 cânceres perdidos	39 acertos

O ponto de atenção são os 3 falsos negativos: três cânceres classificados como benignos, o erro mais grave neste problema. O SVM ajustado, medido no teste só para registro, teve a mesma matriz de confusão.

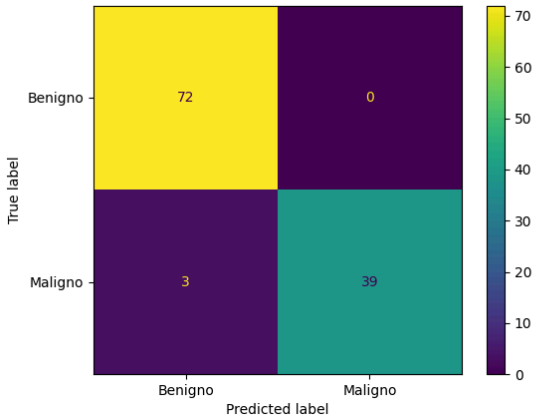


Figura 5 — Matriz de confusão do Random Forest no teste

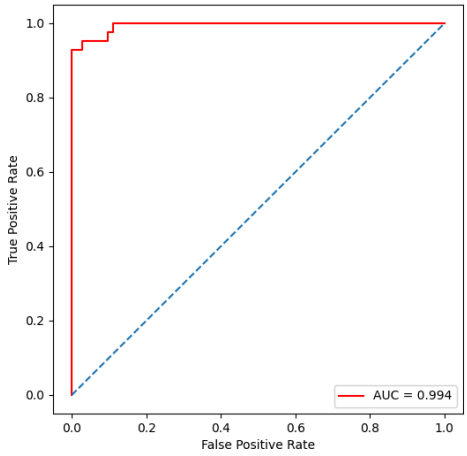


Figura 6 — Curva ROC do Random Forest no teste

Overfitting. A acurácia foi de 1,00 no treino, 0,960 na validação cruzada e 0,974 no teste. O Random Forest quase sempre acerta todo o treino, porque cada árvore cresce até o fim. O que importa é que a validação e o teste ficaram próximos, sinal de que o modelo generaliza para pacientes novos.

Interpretação. Para interpretar o modelo, usamos a importância das variáveis do Random Forest (`feature_importances_`), que mede quanto cada coluna ajudou a separar as classes, na média de todas as árvores. As cinco colunas mais importantes foram `perimeter_worst` (0,143), `area_worst` (0,142), `concave points_worst` (0,113), `concave points_mean` (0,089) e `radius_worst` (0,083).

Essas colunas formam dois grupos: o tamanho do núcleo da célula (perímetro, área e raio) e a concavidade (pontos côncavos). O resultado combina com a análise de correlação e faz sentido médico, já que células malignas tendem a ser maiores e mais irregulares. Como várias colunas repetem a mesma informação, a importância se divide entre elas. Por isso, interpretamos os grupos, e não cada coluna isolada.

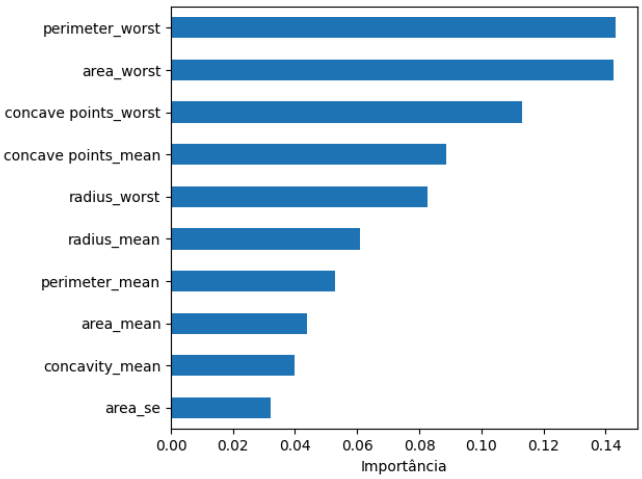


Figura 7 — As 10 colunas mais importantes do Random Forest

SHAP: o que pesou para cada paciente. A importância das variáveis dá um número só para o modelo todo e tem três limites: não diz a direção (se um valor alto empurra para maligno ou para benigno), não explica a decisão de um paciente e se divide entre colunas que repetem informação. O SHAP (Lundberg

e Lee, 2017), que o enunciado cita, resolve os dois primeiros. Para cada paciente, ele parte da chance média de câncer do modelo (cerca de 0,37, perto da proporção de malignos no treino) e mostra quanto cada coluna somou ou tirou até chegar à chance daquele paciente.

O resultado confirma a importância das variáveis: as 5 colunas que mais pesam pelo SHAP são as mesmas 5, só em outra ordem (`area_worst`, `perimeter_worst`, `concave points_worst`, `concave points_mean` e `radius_worst`). O gráfico de resumo mostra também a direção: cada ponto é um paciente, e valores altos dessas colunas (pontos vermelhos) empurram para maligno, enquanto valores baixos (pontos azuis) empurram para benigno. O terceiro limite continua: no SHAP, perímetro, área e raio também dividem o peso entre si. Por isso, lemos os grupos de colunas (tamanho e concavidade), e não cada coluna sozinha.

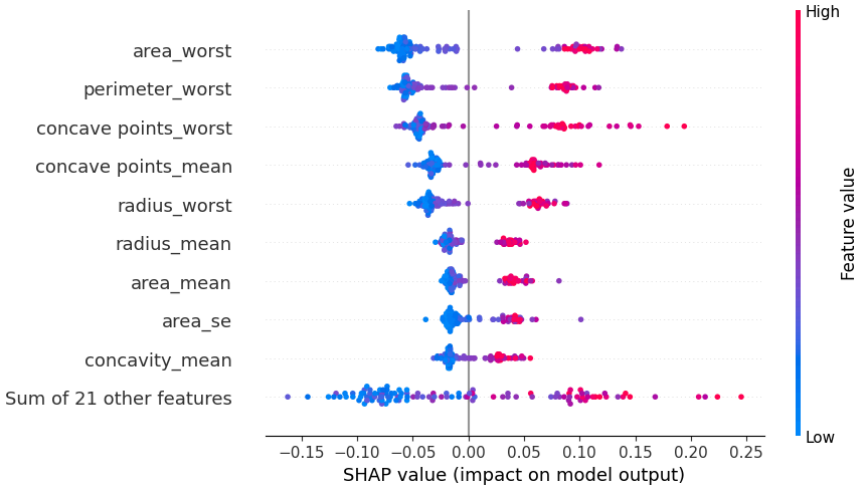


Figura 8 — SHAP: resumo dos 114 pacientes do teste

Também usamos o SHAP para entender um dos 3 cânceres perdidos. O modelo deu a ele 16% de chance de maligno, abaixo do limiar de 50%. Quase todas as colunas puxaram para benigno, porque as medidas desse paciente estavam mais perto das de um tumor benigno: o raio médio, por exemplo, é 13,8, mais perto da média dos benignos (12,15) do que da dos malignos (17,46). Na cascata, a coluna perimeter_worst dele vale 110,3: abaixo do corte de 112,8 da primeira pergunta da árvore pequena, descrita a seguir. É um caso de fronteira, e isso reforça que um resultado "benigno" não dispensa o exame do médico.

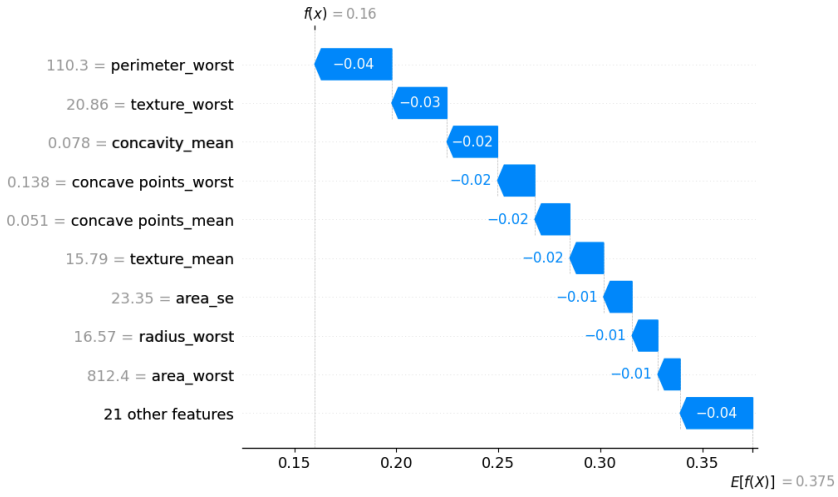


Figura 9 — SHAP: cascata de um câncer que o modelo deixou passar

Para mostrar regras de decisão de um jeito simples, treinamos também uma árvore de decisão com 3 níveis. Ela é um modelo à parte, treinado com os mesmos dados: mostra regras parecidas, mas não é o Random Forest. A primeira pergunta da árvore é se `perimeter_worst` é menor ou igual a 112,8 (tamanho); depois vêm os pontos côncavos (concavidade) e a textura. Tamanho e concavidade são os mesmos grupos da importância das variáveis; a textura aparece aqui, mas não está entre as 10 colunas mais importantes do Random Forest. Em cada caixa da figura, samples é o número de pacientes e value é a contagem [benignos, malignos]. Essa árvore serve só para explicar: sozinha, ela acerta 90% dos casos e encontra 79% dos cânceres, abaixo do Random Forest.

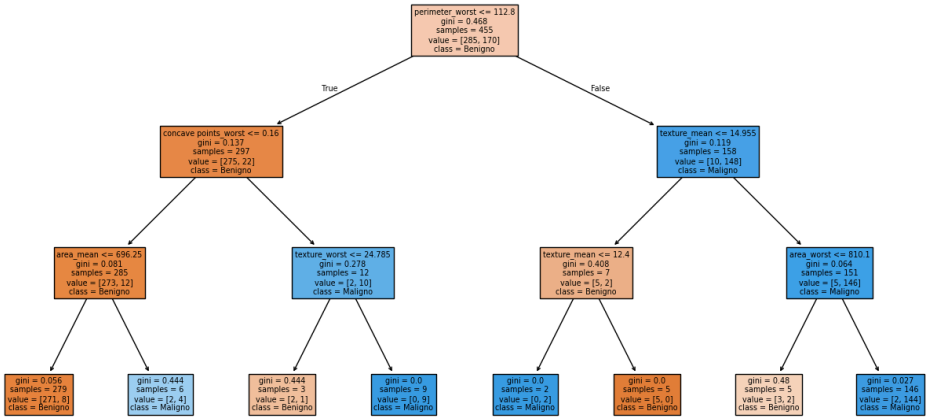


Figura 10 — Árvore de decisão com 3 níveis

Limiar de decisão: cânceres perdidos × alarmes falsos. O Random Forest dá uma chance de câncer para cada paciente, e os resultados acima usam o limiar padrão: quem tem chance de 0,5 ou mais vira "maligno". Os 3 cânceres perdidos tiveram chance abaixo disso (0,16; 0,19 e 0,30). Baixar o limiar pega mais cânceres, mas aumenta os alarmes falsos. Para medir essa troca sem usar o teste na escolha, calculamos uma chance de validação para cada paciente do treino com a validação cruzada (`cross_val_predict`): cada chance vem de um modelo que não viu aquele paciente. Com essas chances, achamos o limiar que atinge cada meta de recall no treino e só depois conferimos no teste. Cada chance vem de um modelo treinado com 4/5 do treino, e o modelo final usa o treino todo; por isso, o limiar é uma boa aproximação, não um valor exato.

Meta de recall na validação	Limiar	Cânceres perdidos no teste	Alarmes falsos no teste
padrão	0,5	3 de 42	0 de 72
98%	0,21	2 de 42	6 de 72 (8%)
99%	0,03	0 de 42	23 de 72 (32%)
100%	0,007	0 de 42	44 de 72 (61%)

Os primeiros cânceres saem baratos, e os últimos, caros. Na validação, descer de 0,5 para 0,21 pega 8 cânceres a mais, ao custo de cerca de 3 alarmes falsos por câncer. Descer de 0,21 para 0,03 pega só mais 2, ao custo de mais de 30 alarmes por câncer. No treino, um câncer recebeu chance de só 0,007, porque suas medidas parecem as de um tumor benigno, como no caso explicado pelo SHAP. Por isso, nenhum limiar garante zero câncer perdido em pacientes novos sem chamar de maligno a maior parte dos benignos. A escolha do limiar depende de quantos exames extras o hospital aceita para cada câncer a mais encontrado, e cabe à equipe médica.

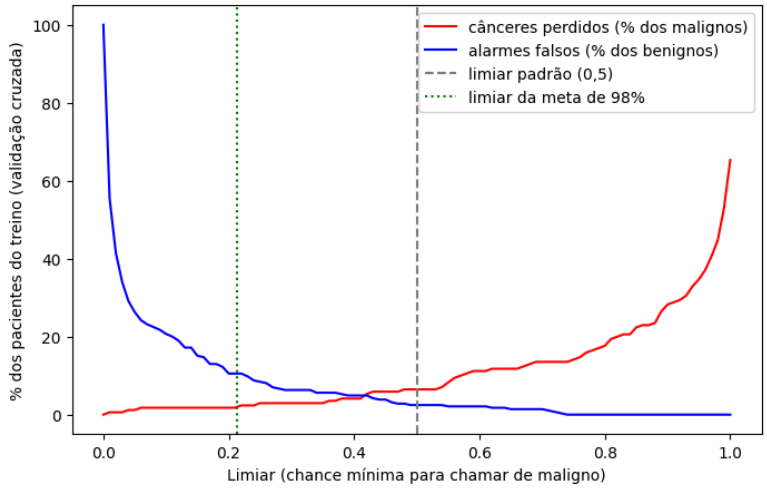


Figura 11 — Troca entre cânceres perdidos e alarmes falsos conforme o limiar (validação cruzada no treino)

2.5 Discussão crítica

Limites. O modelo ainda erra: perdeu 3 dos 42 cânceres do teste, cerca de 7%. Além disso, a base é pequena (569 pacientes) e vem de um único centro, a Universidade de Wisconsin (EUA), com dados coletados no início dos anos 1990. Antes de usar o modelo num hospital, é preciso testá-lo com pacientes desse hospital. As medidas também precisam ser obtidas do mesmo jeito, a partir de imagens digitalizadas de punção por agulha fina.

Limiar de decisão. O modelo dá uma probabilidade, e o padrão é chamar de maligno quem passa de 0,5. Medimos essa troca (seção 2.4): com um limiar de 0,03, escolhido na validação, o modelo não perderia nenhum dos 42 cânceres do teste, mas daria 23 alarmes falsos entre os 72 benignos. O limiar deve ser escolhido com a equipe médica, usando dados de validação e nunca o teste.

Próximos passos. Testar o modelo com dados do próprio hospital e definir o limiar junto com a equipe médica.

Conclusão. O Random Forest encontrou 93% dos cânceres do teste, sem nenhum alarme falso, e suas decisões se apoiam em medidas que fazem sentido médico: o tamanho e a concavidade das células. Esse modelo já é uma boa base para um sistema de apoio à triagem.

3. Parte B (extra): pneumonia em raio-X

3.1 Base de dados: Chest X-Ray Images (Pneumonia)

A base, também do Kaggle, tem 5.856 radiografias de tórax de crianças de 1 a 5 anos, feitas no Guangzhou Women and Children's Medical Center, na China. As classes são NORMAL e PNEUMONIA, e as imagens já vêm divididas em pastas:

Pasta	NORMAL	PNEUMONIA	Uso no trabalho
`train`	1.341	3.875	treino e validação
`val`	8	8	não usada: pequena demais
`test`	234	390	teste final

A pasta `val` tem só 16 imagens, e uma nota medida em tão poucas imagens dependeria muito da sorte. Por isso, criamos a nossa própria validação a partir do treino (seção 3.2).

Métrica. Além do recall de PNEUMONIA, o recall da classe saudável (NORMAL) funciona como trava. Sem ela, um modelo que chamasse todos de doentes teria recall 1,0 na classe doente e não serviria para nada.

3.2 Pré-processamento

Ambiente. A Parte B roda no Google Colab, com GPU, e usa o TensorFlow 2.21.0.

Pré-processamento das imagens. As radiografias têm tamanhos diferentes. Todas foram convertidas para tons de cinza (1 canal) e redimensionadas para 128 × 128 pixels. Para o modelo sem rede neural (seção 3.3), elas foram reduzidas mais uma vez, para 64 × 64. Depois, os pixels foram divididos por 255 e ficaram entre 0 e 1. Essa divisão usa um número fixo e não aprende nada dos dados, então não vaza informação do teste. Como na Parte A, a classe doente recebeu o rótulo 1 (NORMAL = 0 e PNEUMONIA = 1), para que o recall e o F1 sejam calculados para ela.

Exploração das imagens. O treino tem 1.341 imagens NORMAL e 3.875 PNEUMONIA, ou seja, 74% são de doentes. Com esse desequilíbrio, um modelo que sempre dissesse "pneumonia" já teria 74% de acurácia. No teste, a proporção muda: 62,5% das imagens são de PNEUMONIA.

Na imagem média, os doentes aparecem mais claros na região central, onde ficam os pulmões. Isso é esperado: no raio-X, a pneumonia aparece como áreas mais brancas no pulmão. O brilho médio é de 122,4 nas imagens NORMAL e de 123,2 nas de PNEUMONIA, numa escala de 0 a 255. Os dois são quase iguais: o brilho geral, sozinho, não separa as classes.

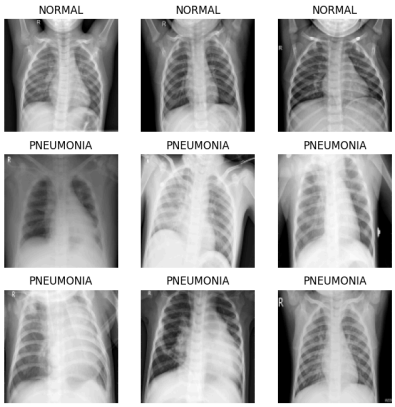


Figura 12 — Nove radiografias de treino, NORMAL e PNEUMONIA

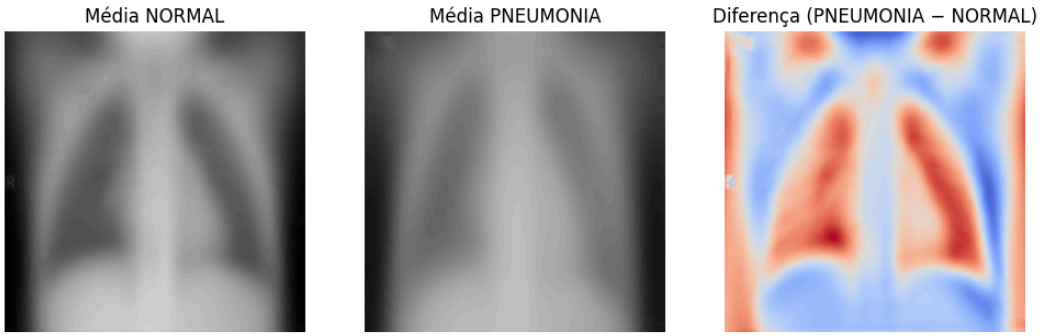


Figura 13 — Raio-X médio de cada classe e a diferença entre eles

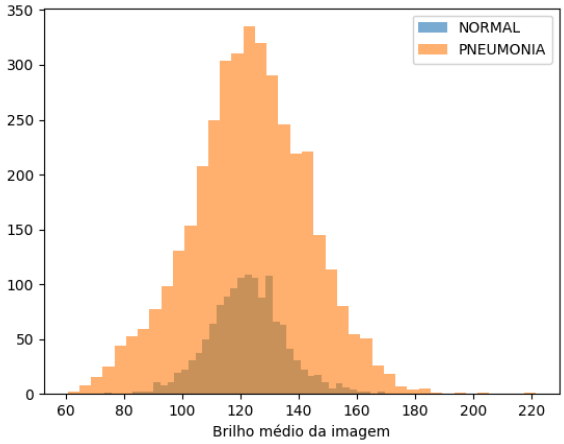


Figura 14 — Brilho médio das imagens, por classe

Treino, validação e teste. O teste é a pasta `test` da base, com 624 imagens, usada só no fim, depois da escolha do modelo. A validação saiu de dentro do treino e foi separada por paciente: as radiografias de uma mesma criança ficam todas no treino ou todas na validação. Sem isso, a rede seria avaliada com crianças que já viu: num sorteio por imagem, 413 das 1.044 imagens de validação seriam de crianças que também estão no treino. O código do paciente vem do nome do arquivo (por exemplo,

`person12_bacteria`), e a divisão usa o `StratifiedGroupKFold`, que também mantém a proporção de PNEUMONIA (74%) nas duas partes. Assim, ficaram 4.181 imagens para treinar e 1.035 para validar. O teste oficial não tem nenhum paciente do treino.

Correlação entre pixels. Medir a correlação pixel a pixel não ajuda a entender uma imagem, mas o PCA mostra a mesma ideia da Parte A: das 4.096 colunas de pixels (cada imagem reduzida a 64 × 64 para esse modelo), 246 componentes já guardam 95% da informação. Pixels vizinhos repetem informação, assim como raio, perímetro e área.

3.3 Modelos usados e por quê

Testamos três modelos: duas CNNs e uma solução sem rede neural.

Modelo	O que é	Parâmetros	Por que testar
CNN 1	3 convoluções (32, 64 e 64 filtros), 2 max pooling e uma camada densa de 64	3.267.202	ponto de partida simples
CNN 2	a CNN 1 com 128 filtros na 3ª convolução, um max pooling a mais e Dropout de 50%	1.698.498	menos parâmetros e menos overfitting
PCA + Random Forest	cada imagem vira uma linha de tabela, reduzida pelo PCA e classificada pelo Random Forest	—	mostra se a CNN supera um modelo clássico

CNN 1. É uma rede convolucional simples. Ela recebe a imagem de 128 × 128 × 1 e termina em 2 saídas com softmax, uma por classe. Quase todos os seus parâmetros ficam na camada densa, que recebe um vetor de 50.176 números.

CNN 2. Na CNN 2, a terceira convolução passa a ter 128 filtros e ganha um max pooling. Com isso, o vetor que entra na camada densa cai para 25.088 números, e o total de parâmetros cai para 1,70 milhão. Antes da saída, o Dropout desliga neurônios ao acaso durante o treino, para reduzir o overfitting. Para uma comparação justa, as duas CNNs usam a mesma semente, o otimizador Adam e 10 épocas, um número que cabe no tempo do Colab gratuito. As CNNs não usam peso por classe: com 74% de pneumonia no treino, elas tendem a apontar mais pneumonia, o que ajuda o recall da classe doente, mas pode gerar mais alarmes falsos. A trava do recall de NORMAL controla esse efeito na validação.

PCA + Random Forest. Aqui, cada imagem é reduzida a 64 × 64 pixels e vira uma linha com 4.096 colunas, uma por pixel. Um Pipeline padroniza as colunas, aplica o PCA (95% da informação) e treina um Random Forest com 300 árvores, como na Parte A. Ele também usa `class_weight='balanced'`, porque 74% das imagens de treino são de pneumonia: o peso maior na classe NORMAL evita que o modelo chame quase todos de doentes.

Regra de escolha. Primeiro, descartamos os modelos com recall de NORMAL abaixo de 0,80 na validação, ou seja, os que erram mais de 1 em cada 5 exames normais. Entre os que sobram, vence o de maior recall de PNEUMONIA. Se a diferença for de até 0,02 (cerca de 15 das 770 pneumonias da validação), consideramos empate, e vence o de maior recall de NORMAL. Se nenhum modelo passar da trava, vence o que chegar mais perto dela. O notebook aplica essa regra sozinho, antes de olhar o teste.

Comparação na validação. A tabela usa as 1.035 imagens de validação.

Modelo	Recall PNEUMONIA	Recall NORMAL	F1	Acurácia
CNN 1	0,984	0,921	0,979	0,968
CNN 2	0,978	0,951	0,980	0,971
PCA + RF	0,996	0,475	0,915	0,863

Pela regra de escolha, o modelo final é a CNN 2, com recall de 0,978 para PNEUMONIA e de 0,951 para NORMAL na validação. Os outros dois modelos tiveram recall de PNEUMONIA de 0,984 (CNN 1) e 0,996 (PCA + RF). A CNN 1 teve recall de PNEUMONIA um pouco maior, mas a diferença ficou dentro da margem de empate (0,02), e a CNN 2 errou menos os exames normais. O PCA + RF teve recall de PNEUMONIA maior, mas foi descartado por errar demais os exames normais (recall de NORMAL abaixo de 0,80).

3.4 Resultados e interpretação

Curvas de treino. Na CNN 1, a perda de validação foi mínima na época 4 e voltou a subir depois, um sinal de overfitting. Na CNN 2, a perda de validação não voltou a subir de forma clara, sem sinal forte de overfitting. Medida depois do treino, a acurácia de treino ficou 2,7 pontos acima da de validação na CNN 1 e 0,6 ponto na CNN 2. Quanto maior essa distância, mais a rede decorou o treino. As mudanças da CNN 2 (mais filtros, um pooling a mais e Dropout) reduziram essa distância.

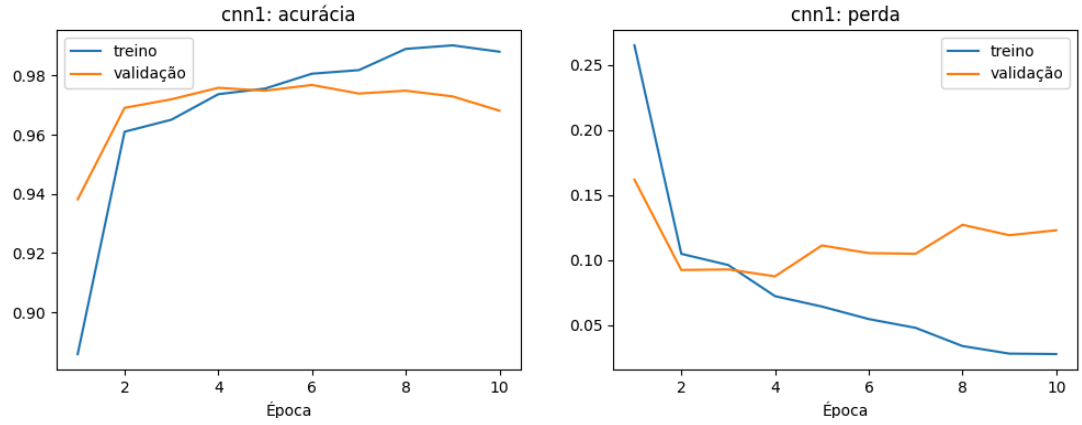


Figura 15 — CNN 1: acurácia e perda por época, no treino e na validação

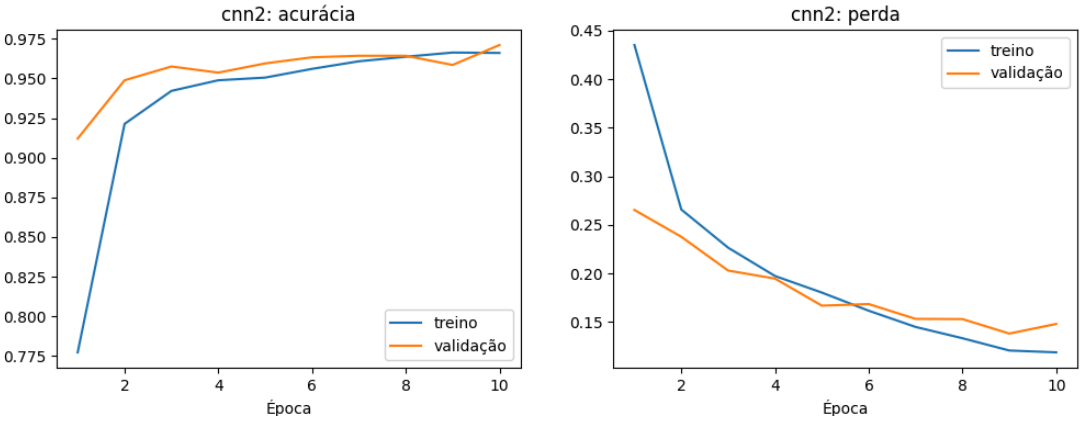


Figura 16 — CNN 2: acurácia e perda por época, no treino e na validação

Resultado no teste. No teste, com 624 imagens (234 NORMAL e 390 PNEUMONIA), a CNN 2 encontrou 385 das 390 pneumonias, um recall de 0,987. Deixou passar 5 casos, o erro mais grave neste problema. Entre os 234 exames normais, acertou 95 (recall de 0,406) e deu 139 alarmes falsos. A AUC foi de 0,896. O recall de NORMAL caiu de 0,951, na validação, para 0,406, no teste. Uma explicação provável: a validação vem da mesma pasta do treino, e o teste foi montado à parte. Por isso, a validação não mostrou essa queda. Para comparação, a CNN 1 deixou passar 1 pneumonia e o PCA + RF não deixou passar nenhuma pneumonia.

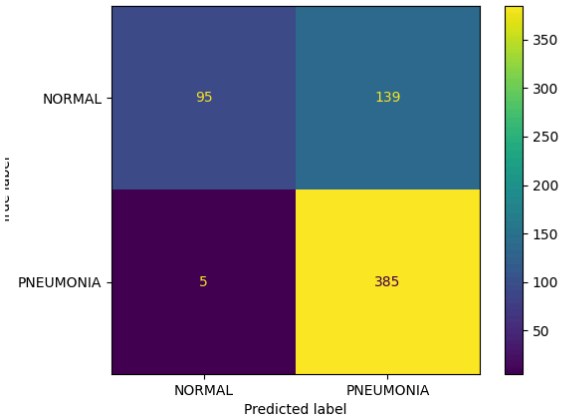


Figura 17 — Matriz de confusão do modelo final da Parte B no teste

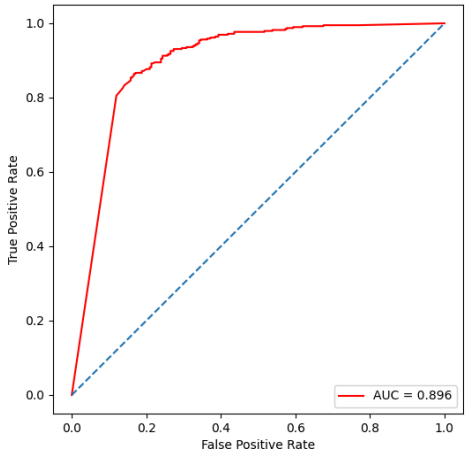


Figura 18 — Curva ROC do modelo final da Parte B no teste

Interpretação. Além da matriz de confusão, que mostra o tipo de erro, usamos três ferramentas. A grade de previsões mostra exemplos de acertos (em azul) e de erros (em vermelho). O mapa de oclusão (Zeiler e Fergus, 2014) mostra o que pesou na decisão: ele cobre um quadrado da imagem por vez e mede quanto a certeza de pneumonia cai. Como o SHAP da Parte A, ele explica uma imagem por vez; usamos a oclusão porque, com imagens, o SHAP é bem mais lento e difícil de ler. Por fim, medimos quanto do peso do mapa fica no centro da imagem, onde estão os pulmões.

Na matriz de confusão, há 5 falsos negativos e 139 falsos positivos. No mapa de oclusão, medido em 15 acertos de pneumonia, 53% do peso ficou na região central da imagem, que ocupa 56% da área. Ou seja, uma parte importante do peso está nas bordas, fora dos pulmões. O modelo pode estar usando pistas que não são a doença, como marcações do aparelho.

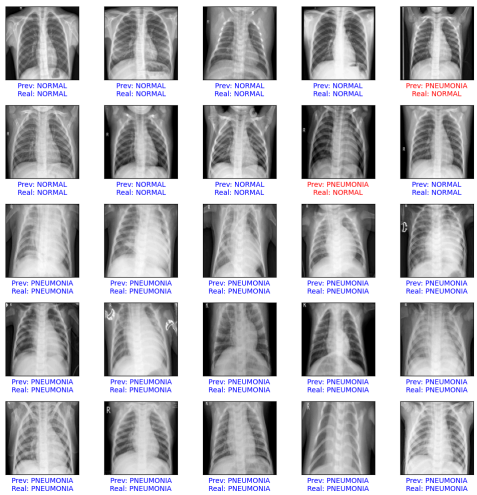


Figura 19 — Grade de 25 previsões do teste: azul é acerto, vermelho é erro

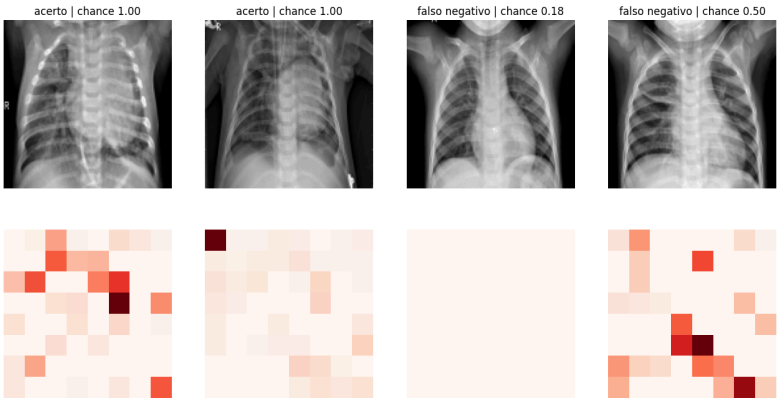


Figura 20 — Mapa de oclusão: raio-X em cima e o peso de cada quadrado embaixo

3.5 Discussão crítica

Limites. No teste, o modelo de imagens deixou passar 5 pneumonias das 390 e deu 139 alarmes falsos. A base tem só crianças de 1 a 5 anos, de um único hospital chinês, então o modelo não vale para adultos nem para outros aparelhos sem um novo teste. A validação foi separada por paciente, mas não previu a queda do recall de NORMAL no teste (seção 3.4). Por fim, as imagens foram reduzidas para 128 × 128 pixels, em cinza, e perdem detalhes que o médico enxerga.

Limiar de decisão. Como na Parte A, o modelo dá uma probabilidade, e o padrão é chamar de pneumonia quem passa de 0,5. A curva ROC mostra a mesma troca entre doentes perdidos e alarmes falsos. O limiar também deve ser escolhido com a equipe médica, usando dados de validação e nunca o teste.

Próximos passos. Testar o modelo com dados do próprio hospital, usar peso por classe e aumento de dados nas CNNs e parar o treino na melhor época.

Conclusão. A CNN 2 encontrou 99% das pneumonias do teste, mas o recall entre os exames normais foi de só 0,41. O modelo de imagens ainda dá alarmes falsos demais e precisa melhorar antes de qualquer uso.

4. Uso na prática

Os modelos servem para apoiar a triagem, e não para dar o diagnóstico. Hoje, só o da Parte A está perto disso; o da Parte B ainda dá alarmes falsos demais. Na prática, o modelo entra depois do exame e antes da consulta. Para cada exame, ele mostra a chance de doença e o que mais pesou na decisão (as colunas ou as áreas da imagem), e os casos com chance alta sobem na fila do médico. Um resultado "não doente" nunca dispensa o paciente: todos os exames continuam sendo vistos pelo médico, que tem a palavra final. O hospital também precisa acompanhar os erros do modelo ao longo do tempo e seguir as regras da Anvisa para software usado em saúde.

Referências

Bases de dados

- Wolberg, W.; Mangasarian, O.; Street, N.; Street, W. (1993). Breast Cancer Wisconsin (Diagnostic). UCI Machine Learning Repository. DOI 10.24432/C5DW2B. Versão usada: Kaggle.
- Kermany, D.; Zhang, K.; Goldbaum, M. (2018). Large Dataset of Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images. Mendeley Data, v3. DOI 10.17632/rscbjbr9sj.3. Versão usada: Chest X-Ray Images (Pneumonia), Kaggle.

Artigos

- Kermany, D. et al. (2018). Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell*, 172(5), 1122–1131. DOI 10.1016/j.cell.2018.02.010.
- Zeiler, M.; Fergus, R. (2014). Visualizing and Understanding Convolutional Networks. ECCV 2014, seção 4.2 (teste de oclusão).
- Lundberg, S.; Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS 2017 (SHAP).
- Srivastava, N. et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research*, 15, 1929–1958.
- TensorFlow. Convolutional Neural Network (CNN), tutorial oficial. https://www.tensorflow.org/tutorials/images/cnn