Relatório Técnico — Tech Challenge Fase 1

27 de out. de 2026

Pós-Tech IA para Devs (FIAP) · Fase 1

Repositório Git: github.com/gabrielrb/tech-challenge-fase1

Resumo

Este trabalho apresenta dois modelos de apoio à triagem médica. Na Parte A, uma regressão logística classifica nódulos da mama como malignos ou benignos a partir de 30 medidas das células. Na Parte B, comparamos duas redes neurais convolucionais e um modelo clássico para detectar pneumonia em radiografias de tórax. Nas duas partes, a métrica principal é o recall da classe doente, porque o erro mais grave é deixar um doente sem diagnóstico. Na Parte A, o grupo considerou que perder um câncer é pelo menos 10 vezes pior do que um alarme falso, e o modelo e o limiar de decisão foram escolhidos com essa regra.

Parte	Problema	Modelo final	Recall da classe doente (teste)	Outras métricas (teste)
A	câncer de mama (tabela)	regressão logística, limiar 0,097	0,98 (41 de 42 cânceres)	5 alarmes falsos em 72 benignos · acurácia 0,95 · precisão 0,89 · F1 0,93 · AUC 0,996
B	pneumonia (raio-X)	CNN 2	0,99 (385 de 390 pneumonias)	recall de NORMAL 0,41 · AUC 0,896

1. Problema e métrica

1.1 O problema

Um hospital universitário quer um sistema de apoio ao diagnóstico para acelerar a triagem de exames. Nesta fase, o sistema classifica cada exame como "doente" ou "não doente". Ele aponta os casos suspeitos para o médico olhar primeiro, mas a decisão final é sempre do médico. Os dois problemas são de classificação supervisionada: cada exame já tem a resposta certa, e essa resposta é uma categoria.

1.2 Métrica principal

O erro mais grave é o falso negativo: dizer que um doente está saudável, o que atrasa o tratamento. Por isso, a métrica principal das duas partes é o recall da classe doente, que mostra quantos dos doentes reais o modelo encontra. Também olhamos a precisão (dos exames que o modelo chamou de doentes, quantos eram mesmo doentes), o F1 (uma nota que junta recall e precisão) e a acurácia (o total de acertos). A acurácia sozinha engana quando as classes são desiguais. A AUC resume a curva ROC: vai de 0,5 (um chute) a 1,0 (separação perfeita).

2. Parte A: câncer de mama (dados em tabela)

2.1 Base de dados: Breast Cancer Wisconsin (Diagnostic)

A base vem da UCI e foi baixada do Kaggle. Ela tem 569 pacientes e 30 medidas numéricas do núcleo das células, tiradas de imagens digitalizadas de punção por agulha fina. São 10 medidas, como raio, textura, área e concavidade, cada uma em três versões: média, erro padrão e pior valor. O alvo é a coluna `diagnosis`, com 212 tumores malignos (37%) e 357 benignos (63%).

2.2 Pré-processamento

Exploração dos dados. Começamos com estatísticas descritivas, a contagem das classes e gráficos de distribuição por classe. Quatro achados guiaram o pré-processamento:

1. As classes são desiguais (63% benignos e 37% malignos), por isso a divisão dos dados foi estratificada.
2. As medidas separam bem as classes: os tumores malignos têm raio e área maiores e mais pontos côncavos (tabela abaixo).
3. As colunas têm escalas muito diferentes: `area_mean` chega a 2.501, enquanto `smoothness_mean` fica perto de 0,1. Por isso, os modelos que usam somas ou distâncias (regressão logística, KNN e SVM) recebem dados padronizados.
4. Há valores extremos, mas eles batem com o raio e o perímetro do mesmo paciente, então não parecem erro de digitação. Não os removemos, porque isso apagaria justamente os casos malignos mais claros.

Médias por classe. A tabela compara quatro medidas entre benignos e malignos.

Medida (média)	Benigno	Maligno
`radius_mean` (raio)	12,15	17,46
`area_mean` (área)	462,79	978,38
`concave points_mean` (pontos côncavos)	0,03	0,09
`texture_mean` (textura)	17,91	21,60

Raio, área e pontos côncavos mudam muito entre as classes. A textura muda menos, e o histograma mostra muita sobreposição entre benignos e malignos.

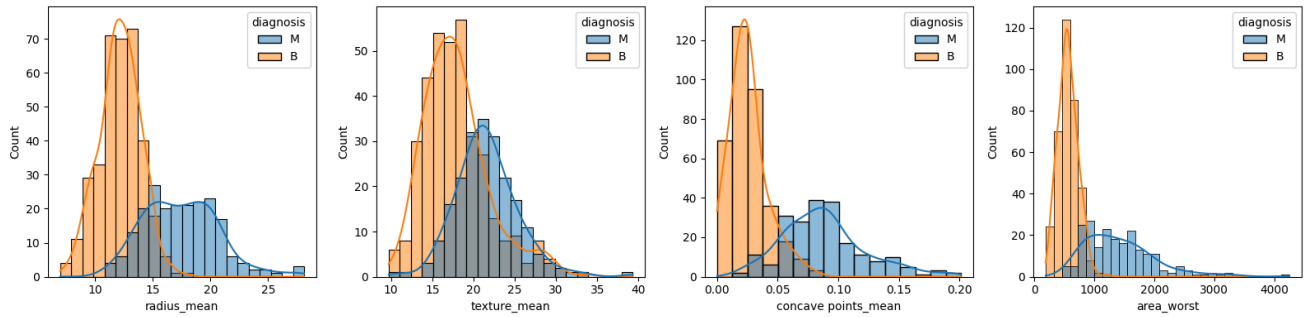


Figura 1 — Histogramas de quatro medidas, por classe (M = maligno, B = benigno)

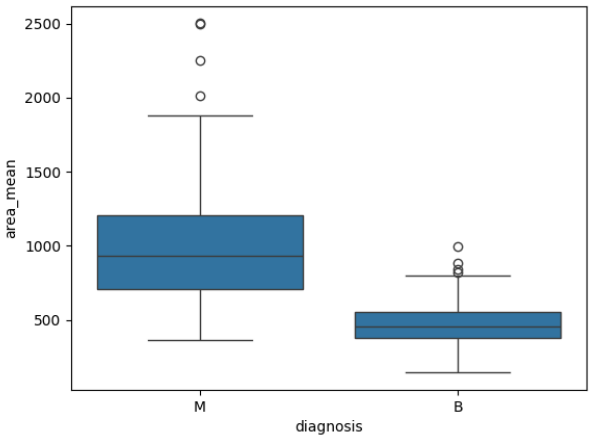


Figura 2 — Boxplot da área média por classe

Limpeza e conversão. Fora a coluna Unnamed: 32, que está toda vazia, a base não tem valores ausentes nem pacientes repetidos. A tabela abaixo resume as decisões de limpeza. Duas delas merecem explicação. O alvo foi convertido com o LabelEncoder (benigno = 0 e maligno = 1): com só duas categorias, isso não cria uma ordem falsa, e o recall e o F1 passam a ser calculados para a classe maligna. Já a padronização (StandardScaler) ficou dentro de um Pipeline, para aprender a média e o desvio só com os dados de treino e evitar vazamento de dados. O One-Hot Encoding não foi necessário, porque as 30 colunas de entrada já são numéricas.

Decisão	Motivo
`id` removida	é só um código e não ajuda a prever
`Unnamed: 32` removida	a coluna está vazia
nenhuma linha removida	não há nulos nem duplicados nas medidas
zeros mantidos nas colunas de `concavity` e `concave points` (os mesmos 13 pacientes, todos benignos, nas 6 colunas de concavidade)	são valores reais, de células sem concavidade
alvo com LabelEncoder (maligno = 1)	o recall e o F1 ficam na classe maligna
padronização dentro do Pipeline	o `fit` usa só o treino

Análise de correlação. As colunas mais ligadas ao câncer são `concave points_worst` (0,79), seguida de `perimeter_worst`, `concave points_mean` e `radius_worst` (0,78 cada). Isso mostra uma associação, não uma causa: tumores malignos tendem a ter células maiores e com mais concavidades. Outras colunas quase não têm relação com o diagnóstico, como `fractal_dimension_mean` (−0,01).

As colunas também repetem informação entre si: 21 pares têm correlação acima de 0,9. Por exemplo, `radius_mean` e `perimeter_mean` têm correlação de 0,998, porque raio, perímetro e área medem o mesmo tamanho da célula. Essa repetição motivou o teste com PCA (seção 2.3).

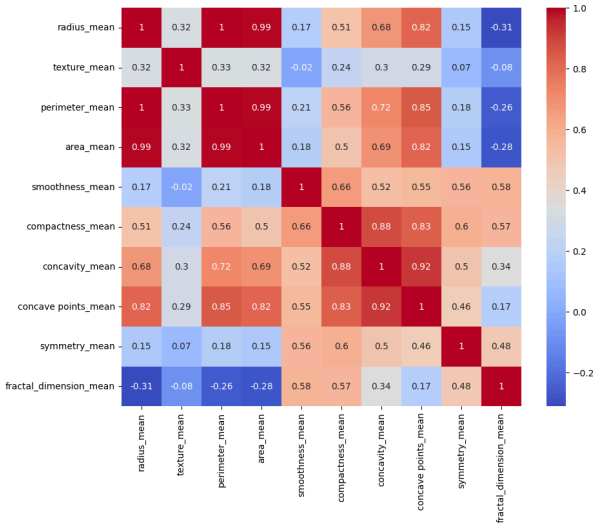


Figura 3 — Correlação entre as 10 colunas "_mean"

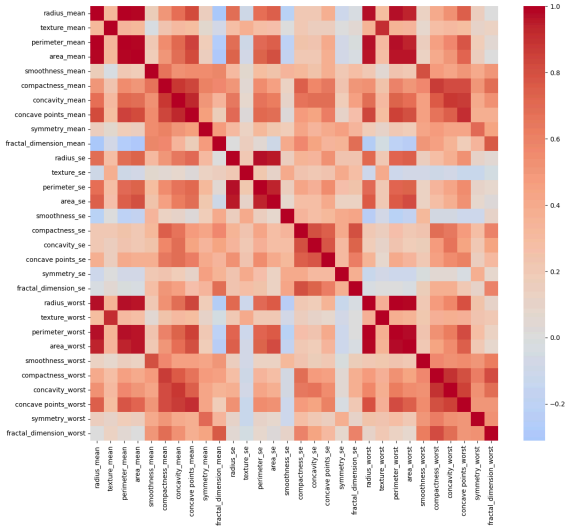


Figura 4 — Correlação entre as 30 colunas

Treino, validação e teste. Separamos 20% dos pacientes (114) para o teste, que ficou guardado até a avaliação final, depois de todas as escolhas (veja "Transparência", na seção 2.4). Os outros 455 (80%) formam o treino. A validação foi feita dentro do treino, com validação cruzada em 5 partes (KFold): cada parte serve de validação uma vez, e assim cada paciente do treino recebe uma previsão de um modelo que não o viu. Para escolher o modelo e o limiar, repetimos a validação cruzada com 10 sorteios diferentes das 5 partes e usamos a média. A separação entre treino e teste foi estratificada e usou `random_state=42`. As 5 partes do KFold foram sorteadas sem estratificar, como na primeira versão do trabalho, então a proporção de malignos varia um pouco entre elas (de 33% a 43%). Isso pesa pouco: em cada sorteio, todos os 170 malignos do treino entram na conta. O StratifiedKFold também seria uma escolha válida. Preferimos a validação cruzada a um bloco fixo de validação porque, com 569 pacientes, esse bloco seria pequeno e a nota dependeria da sorte. A exploração dos dados usou os 569 pacientes, mas só guiou escolhas gerais, como estratificar, padronizar e testar o PCA; o modelo, o C e o limiar saem só da validação. Todos os números da Parte A foram gerados com o scikit-learn 1.6.1; em outra versão, alguns números podem mudar um pouco.

2.3 Modelos usados e por quê

Regra de decisão. Na Parte A, o grupo considerou que perder um câncer é pelo menos 10 vezes pior do que um alarme falso: o câncer perdido atrasa o tratamento, e o alarme falso leva a mais exames, como uma nova biópsia. Por isso, cada modelo foi avaliado pelo **custo = 10 × cânceres perdidos + alarmes falsos**, e o limiar de decisão foi escolhido junto com o modelo, sempre na validação. O recall sozinho não basta, porque chamar todos de malignos daria recall 1,0: o custo junta os cânceres perdidos e os alarmes falsos. O 10 não vem de um estudo: é uma escolha do grupo, que a equipe médica deve rever. Por isso, testamos também os pesos 20 e 50 (abaixo). A regra veio depois de uma primeira versão do trabalho (veja "Transparência", na seção 2.4).

Como medimos. Cada modelo dá uma chance de câncer para cada paciente. Com o `cross_val_predict`, cada paciente do treino recebe a chance dada por um modelo que não o viu. Testamos 1.001 limiares, de 0 a 1, e ficamos com o de menor custo. A validação cruzada foi repetida com 10 sorteios diferentes das 5 partes, e os números são a média dos sorteios. Assim, o limiar não depende da sorte de uma divisão.

Modelos testados. Cinco modelos de classificação, cada um com uma forma diferente de decidir:

Modelo	Como decide	Por que testar
Regressão logística	dá um peso a cada coluna e transforma a soma numa chance	simples e citada no enunciado; os pesos mostram a direção de cada coluna
KNN	pelos pacientes mais parecidos	simples; serve de base de comparação
SVM	pela fronteira com a maior margem entre as classes	bom para bases pequenas com muitas colunas
Árvore de Decisão	por regras do tipo "se / senão"	fácil de explicar ao médico
Random Forest	pelo voto de muitas árvores	menos overfitting que uma árvore só

A regressão logística, o KNN e o SVM foram usados dentro de um Pipeline com StandardScaler, porque dependem da escala das colunas.

Comparação na validação. Média dos 10 sorteios. Os cânceres perdidos são de 170 malignos, e os alarmes falsos, de 285 benignos do treino.

Modelo	Perdidos com limiar 0,5	Limiar de menor custo	Perdidos	Alarmes	Custo
Regressão logística	8,1	0,097	2,3	28,6	51,6
SVM	7,2	0,127	3,1	21,6	52,6
Random Forest	10,2	0,271	4,0	22,5	62,5
KNN	14,7	0,001	3,1	41,4	72,4
Árvore de Decisão	16,7	0,001	16,7	17,8	184,8

Com o limiar padrão de 0,5, os modelos perdem de 7 a 17 cânceres na validação: o limiar importa tanto quanto o modelo. Com o limiar de menor custo, a regressão logística e o SVM ficaram quase iguais (51,6 e 52,6), e com outros sorteios das 5 partes o SVM fica na frente muitas vezes: é um empate técnico no custo. Mas, na regra do grupo, a regressão logística perde menos cânceres (2,3 contra 3,1 de 170); o SVM só empata no custo porque dá menos alarmes falsos (21,6 contra 28,6). O Random Forest perde mais cânceres no seu melhor limiar, e a árvore sozinha é a pior. No KNN e na Árvore, o limiar de 0,001 quer dizer pouco: a Árvore só dá chance 0 ou 1, e o KNN só dá múltiplos de 0,2 (a parte dos 5 vizinhos que é maligna).

Teste com PCA. Por causa dos 21 pares de colunas muito correlacionadas, testamos também a regressão logística com PCA. Ele reduziu as 30 colunas para 10 componentes, guardando 95% da informação, mas o custo subiu de 51,6 para 60,0. Mantivemos as 30 colunas originais, que também são mais fáceis de explicar.

Ajuste do C. Os 5 modelos foram comparados com os ajustes padrão, e só a escolhida, a regressão logística, foi ajustada depois. O principal ajuste dela é o C, que controla quanto o modelo segue o treino. O GridSearchCV mede cada valor com o limiar fixo de 0,5. Como aqui o limiar também é escolhido, a busca usou a mesma régua: para cada C, a validação repetida e o limiar de menor custo.

C	Limiar de menor custo	Perdidos (de 170)	Alarmes (de 285)	Custo
0,01	0,324	5,2	14,5	66,5
0,1	0,234	3,6	16,8	52,8
1	0,097	2,3	28,6	51,6
10	0,107	3,3	21,3	54,3
100	0,001	2,1	42,9	63,9

Modelo final: regressão logística com C = 1 e limiar de 0,097. O C = 1 é também o valor padrão do scikit-learn; o C = 0,1 ficou perto (52,8). Um paciente com chance de câncer de 9,7% ou mais vira "maligno". Ficamos com a regressão logística, e não com o SVM, por dois motivos: no limiar escolhido, ela perde menos cânceres (2,3 contra 3,1 de 170), que é o erro mais grave para o grupo; e cada coluna tem um peso que mostra a direção e a força dela, o que ajuda o médico a entender o modelo. O 0,097 não é um número exato: entre 0,08 e 0,20, o custo fica entre 51,6 e 56,2 (com 0,5, sobe para 84,5), e com outros sorteios o limiar ficaria entre cerca de 0,07 e 0,10. O importante é que o limiar seja baixo, perto de 0,1. Com peso 20 ou 50 no lugar de 10, o limiar desceria para 0,081 ou 0,063, com 0,3 a 0,7 câncer perdido a menos e 4 a 12 alarmes a mais na validação: o limiar muda pouco com o peso. Já o modelo pode mudar: com peso 50, o SVM passaria na frente (111,4 contra 121,0); mesmo assim, ficaríamos com a regressão logística, pela facilidade de explicar. Tudo isso foi decidido antes de olhar o teste com o modelo novo.

2.4 Resultados e interpretação

Transparência. Este trabalho teve uma primeira versão. Nela, o modelo era um Random Forest com limiar de 0,5, e o teste mostrou 3 cânceres perdidos em 42 (7%), sem nenhum alarme falso. O grupo não achou aceitável perder 3 cânceres em 42, e por isso não seguiu com essa versão. A primeira versão também mostrou no teste o SVM, uma árvore pequena e o efeito de baixar o limiar (com 0,03, nenhum câncer perdido e 23 alarmes falsos). Foram esses resultados que levaram o grupo a criar a regra de custo da seção 2.3. Ou seja, o teste já tinha sido visto. Por isso, todas as escolhas novas (modelo, C e limiar) foram feitas só com a validação, e o modelo novo foi avaliado no teste uma única vez, abaixo.

Resultado no teste. No teste, com 114 pacientes (42 deles com câncer), a regressão logística com limiar de 0,097 encontrou 41 dos 42 cânceres: recall de 0,976. Ela deu 5 alarmes falsos entre os 72 benignos. A precisão foi de 0,891, o F1 de 0,932, a acurácia de 0,947 e a AUC de 0,996. Isso está perto do esperado pela validação: cerca de 0,6 câncer perdido e 7 alarmes num teste deste tamanho.

Real \ Previsto	Benigno	Maligno
Benigno (72)	67 acertos	5 alarmes falsos
Maligno (42)	1 câncer perdido	41 acertos

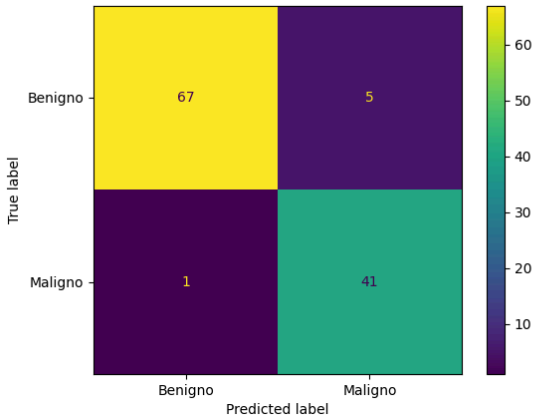


Figura 5 — Matriz de confusão da regressão logística no teste, com limiar de 0,097

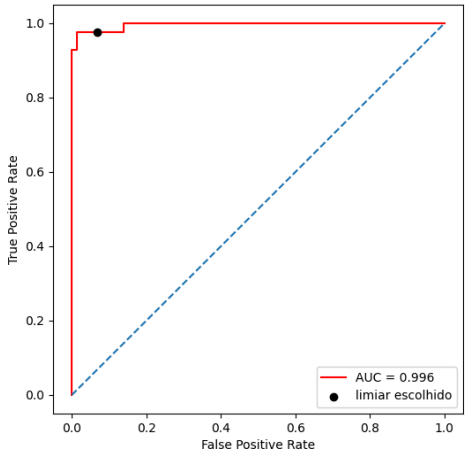


Figura 6 — Curva ROC da regressão logística no teste; o ponto preto é o limiar escolhido

Comparação com o limiar padrão. Com o limiar de 0,5, o mesmo modelo perderia 3 cânceres e daria 1 alarme falso. O Random Forest da primeira versão perdeu 3 e deu 0. Contra o mesmo modelo com limiar de 0,5, a regra de custo trocou 2 cânceres perdidos por 4 alarmes falsos a mais.

Overfitting. O recall foi de 0,994 no treino, 0,986 na validação e 0,976 no teste. A acurácia foi de 0,943, 0,932 e 0,947. Os números ficaram próximos, sinal de que o modelo generaliza para pacientes novos. Os números da validação são um pouco otimistas, porque o limiar foi escolhido com eles; só o teste é uma medida independente.

Interpretação. Usamos a importância das variáveis e o SHAP. Na regressão logística, a importância é o peso de cada coluna: como as colunas foram padronizadas, os pesos podem ser comparados. Peso positivo puxa para maligno; negativo, para benigno. As colunas com maior peso formam grupos: textura (`texture_worst`, a maior), tamanho do núcleo (`radius_se`, `area_se`, `radius_worst`, `area_worst`), concavidade (`concave points_mean`, `concavity_worst`, `concavity_mean`) e simetria (`symmetry_worst`). Valores altos empurram para maligno, o que combina com a análise de correlação e faz sentido médico.

O `compactness_se` aparece com peso negativo. Isso não quer dizer que células mais compactas protejam. Sozinha, essa coluna anda junto com o câncer (correlação de 0,28 no treino). Mas ela repete informação de outras colunas de forma, como a `concavity_se` (correlação de 0,81). Com colunas repetidas, o modelo divide o peso entre elas, e uma pode ficar com o sinal trocado. Por isso, lemos os grupos de colunas, e não cada coluna sozinha.

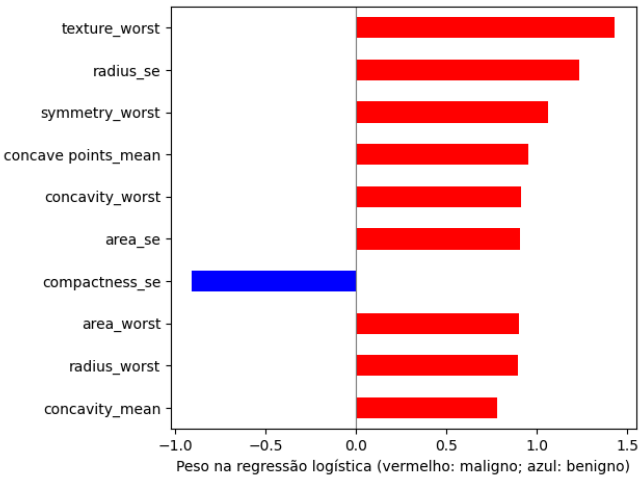


Figura 7 — Os 10 maiores pesos da regressão logística (vermelho: maligno; azul: benigno)

SHAP: o que pesou para cada paciente. O peso vale para o modelo todo e não explica um paciente. O SHAP (Lundberg e Lee, 2017) faz isso: para cada paciente, ele parte da média do modelo e mostra quanto cada coluna somou ou tirou. Na regressão logística, a conta é simples: o SHAP de uma coluna é o peso dela multiplicado por quanto o paciente se afasta da média nessa coluna, na escala interna do modelo (log-odds). As 5 colunas que mais pesam pelo SHAP no teste são `texture_worst`, `radius_se`, `symmetry_worst`, `concave points_mean` e `compactness_se`: os mesmos grupos dos pesos.

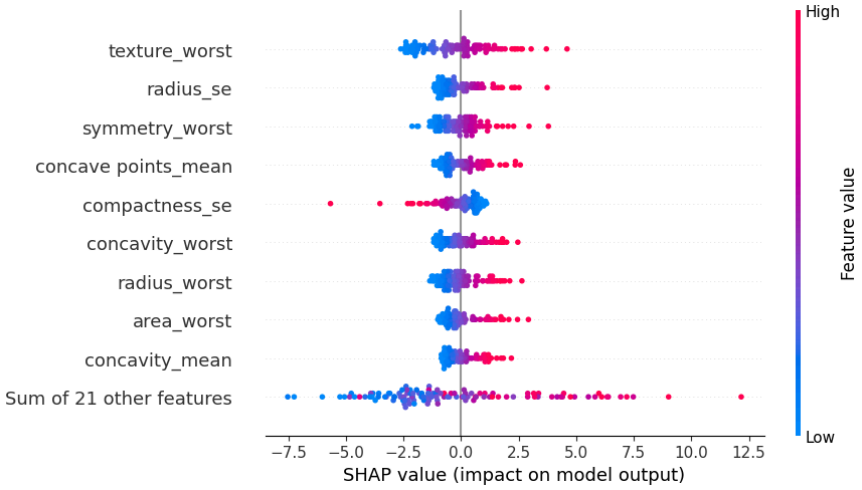


Figura 8 — SHAP: resumo dos 114 pacientes do teste

O caso mais difícil. O câncer perdido no teste recebeu chance de 6,1%, abaixo do limiar de 9,7%. Nem com peso 50 (limiar de 0,063) ele seria encontrado. É o mesmo paciente que o Random Forest da primeira versão também perdia. Na cascata, a maior parte das colunas puxa para benigno: a textura (`texture_worst` = 20,9) é até mais baixa que a média dos benignos do treino (23,7), e a variação do raio (`radius_se` = 0,28) e a simetria (`symmetry_worst` = 0,26) estão no nível dos benignos. Pelas medidas, esse tumor parece benigno. Por isso, um resultado "benigno" nunca dispensa o exame do médico.

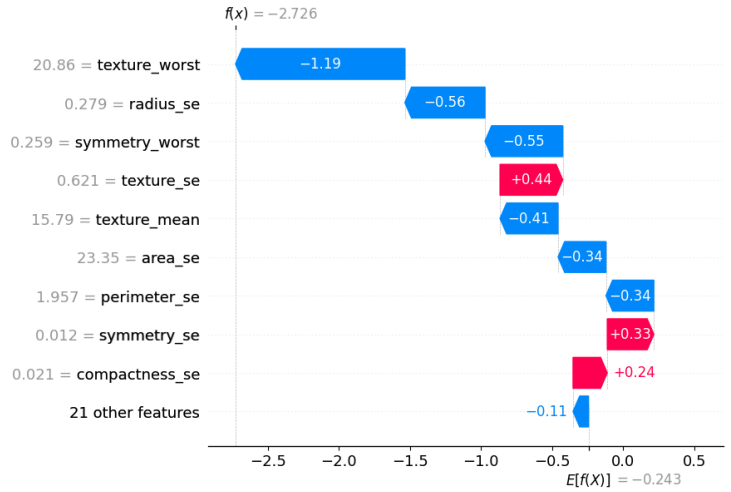


Figura 9 — SHAP: cascata do câncer que o modelo deixou passar

O preço do limiar. Baixar o limiar pega mais cânceres, mas gera mais alarmes falsos:

Limiar	Perdidos na validação (média, de 170)	Alarmes na validação (média, de 285)	Perdidos no teste (de 42)	Alarmes no teste (de 72)
padrão: 0,5	8,1	3,5	3	1
escolhido pelo custo: 0,097	2,3	28,6	1	5
zero perdidos na validação: 0,001	0	171,3	0	40

Os primeiros cânceres saem baratos, e os últimos, caros. Na validação, descer o limiar de 0,5 para 0,097 evita cerca de 6 cânceres perdidos, ao custo de 25 alarmes: cerca de 4 alarmes por câncer. Para não perder nenhum, o limiar teria de cair para 0,001, com alarme para 60% dos benignos: cerca de 62 alarmes para cada câncer a mais. A regra do grupo diz que um câncer vale pelo menos 10 alarmes. Mas, mesmo com peso 50, o limiar de menor custo seria 0,063; o "zero perdidos" só venceria com peso 85 ou mais. E nem ele garantiria zero cânceres perdidos em pacientes novos.

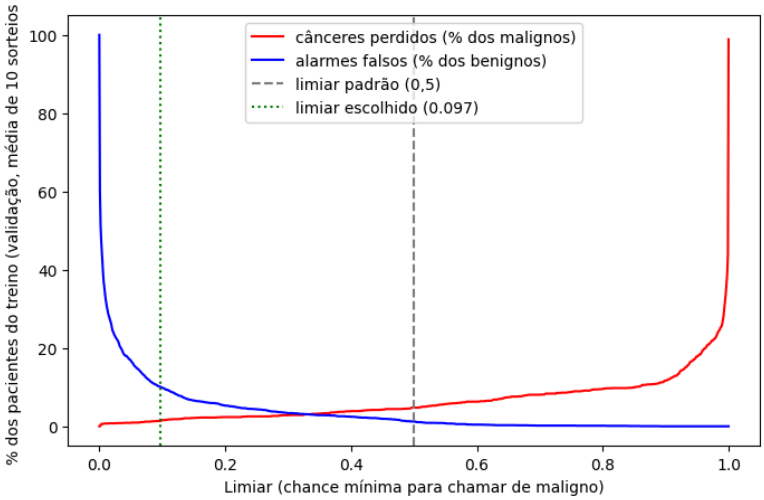


Figura 10 — Troca entre cânceres perdidos e alarmes falsos conforme o limiar (validação, média de 10 sorteios)

2.5 Discussão crítica

Limites. O modelo ainda erra: perdeu 1 dos 42 cânceres do teste (2,4%). Com só 42 cânceres, a taxa real em pacientes novos pode ser maior: o intervalo de confiança de 95% (método exato de Clopper-Pearson) vai até cerca de 13%. O limiar baixo também traz alarmes falsos: 5 dos 72 benignos do teste (7%) seriam chamados para mais exames. Além disso, a base é pequena (569 pacientes) e vem de um único centro, a Universidade de Wisconsin (EUA), com dados coletados no início dos anos 1990. Na base, 37% dos nódulos são malignos; no hospital, essa proporção pode ser outra. Com menos cânceres, haveria mais alarmes para cada câncer encontrado, e a precisão cairia. Antes de usar o modelo num hospital, é preciso testá-lo com pacientes desse hospital e rever o limiar. As medidas também precisam ser obtidas do mesmo jeito, a partir de imagens digitalizadas de punção por agulha fina.

Limiar de decisão. O limiar de 0,097 vem da regra de custo do grupo e foi escolhido só na validação. No uso real, ele deve ser revisto com a equipe médica, com dados do próprio hospital, e nunca com o teste.

Próximos passos. Testar o modelo com dados do próprio hospital, rever o peso da regra de custo com a equipe médica e acompanhar os cânceres perdidos e os alarmes falsos ao longo do tempo.

Conclusão. A regressão logística com limiar de 0,097 encontrou 41 dos 42 cânceres do teste, com 5 alarmes falsos em 72 benignos. Suas decisões se apoiam em medidas que fazem sentido médico: textura, tamanho, concavidade e simetria das células. Esse modelo é uma boa base para um sistema de apoio à triagem, desde que o médico continue vendo todos os exames.

3. Parte B (extra): pneumonia em raio-X

3.1 Base de dados: Chest X-Ray Images (Pneumonia)

A base, também do Kaggle, tem 5.856 radiografias de tórax de crianças de 1 a 5 anos, feitas no Guangzhou Women and Children's Medical Center, na China. As classes são NORMAL e PNEUMONIA, e as imagens já vêm divididas em pastas:

Pasta	NORMAL	PNEUMONIA	Uso no trabalho
`train`	1.341	3.875	treino e validação
`val`	8	8	não usada: pequena demais
`test`	234	390	teste final

A pasta `val` tem só 16 imagens, e uma nota medida em tão poucas imagens dependeria muito da sorte. Por isso, criamos a nossa própria validação a partir do treino (seção 3.2).

Métrica. Além do recall de PNEUMONIA, o recall da classe saudável (NORMAL) funciona como trava. Sem ela, um modelo que chamasse todos de doentes teria recall 1,0 na classe doente e não serviria para nada.

3.2 Pré-processamento

Ambiente. A Parte B roda no Google Colab, com GPU, e usa o TensorFlow 2.21.0.

Pré-processamento das imagens. As radiografias têm tamanhos diferentes. Todas foram convertidas para tons de cinza (1 canal) e redimensionadas para 128 × 128 pixels. Para o modelo sem rede neural (seção 3.3), elas foram reduzidas mais uma vez, para 64 × 64. Depois, os pixels foram divididos por 255 e ficaram entre 0 e 1. Essa divisão usa um número fixo e não aprende nada dos dados, então não vaza informação do teste. Como na Parte A, a classe doente recebeu o rótulo 1 (NORMAL = 0 e PNEUMONIA = 1), para que o recall e o F1 sejam calculados para ela.

Exploração das imagens. O treino tem 1.341 imagens NORMAL e 3.875 PNEUMONIA, ou seja, 74% são de doentes. Com esse desequilíbrio, um modelo que sempre dissesse "pneumonia" já teria 74% de acurácia. No teste, a proporção muda: 62,5% das imagens são de PNEUMONIA.

Na imagem média, os doentes aparecem mais claros na região central, onde ficam os pulmões. Isso é esperado: no raio-X, a pneumonia aparece como áreas mais brancas no pulmão. O brilho médio é de 122,4 nas imagens NORMAL e de 123,2 nas de PNEUMONIA, numa escala de 0 a 255. Os dois são quase iguais: o brilho geral, sozinho, não separa as classes.

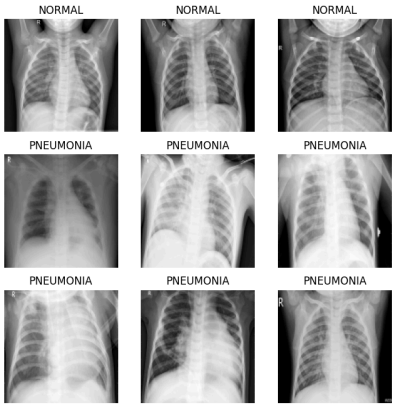


Figura 11 — Nove radiografias de treino, NORMAL e PNEUMONIA

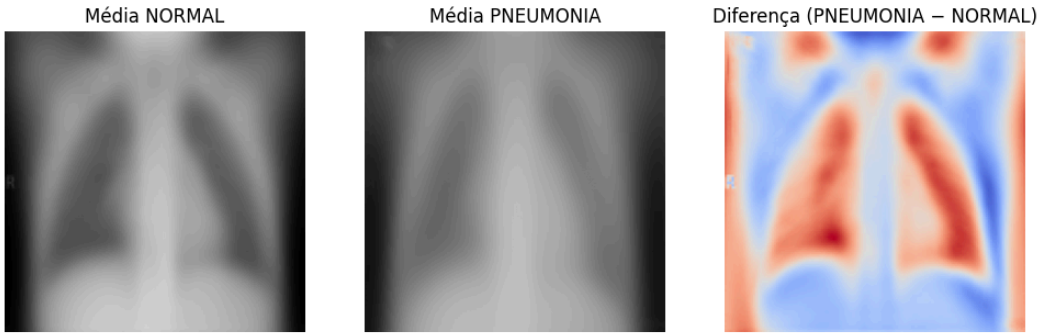


Figura 12 — Raio-X médio de cada classe e a diferença entre eles

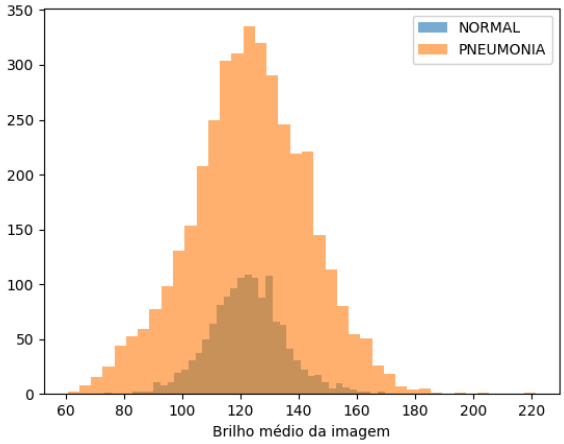


Figura 13 — Brilho médio das imagens, por classe

Treino, validação e teste. O teste é a pasta `test` da base, com 624 imagens, usada só no fim, depois da escolha do modelo. A validação saiu de dentro do treino e foi separada por paciente: as radiografias de uma mesma criança ficam todas no treino ou todas na validação. Sem isso, a rede seria avaliada com crianças que já viu: num sorteio por imagem, 413 das 1.044 imagens de validação seriam de crianças que também estão no treino. O código do paciente vem do nome do arquivo (por exemplo,

`person12_bacteria`), e a divisão usa o `StratifiedGroupKFold`, que também mantém a proporção de PNEUMONIA (74%) nas duas partes. Assim, ficaram 4.181 imagens para treinar e 1.035 para validar. O teste oficial não tem nenhum paciente do treino.

Correlação entre pixels. Medir a correlação pixel a pixel não ajuda a entender uma imagem, mas o PCA mostra a mesma ideia da Parte A: das 4.096 colunas de pixels (cada imagem reduzida a 64 × 64 para esse modelo), 246 componentes já guardam 95% da informação. Pixels vizinhos repetem informação, assim como raio, perímetro e área.

3.3 Modelos usados e por quê

Testamos três modelos: duas CNNs e uma solução sem rede neural.

Modelo	O que é	Parâmetros	Por que testar
CNN 1	3 convoluções (32, 64 e 64 filtros), 2 max pooling e uma camada densa de 64	3.267.202	ponto de partida simples
CNN 2	a CNN 1 com 128 filtros na 3ª convolução, um max pooling a mais e Dropout de 50%	1.698.498	menos parâmetros e menos overfitting
PCA + Random Forest	cada imagem vira uma linha de tabela, reduzida pelo PCA e classificada pelo Random Forest	—	mostra se a CNN supera um modelo clássico

CNN 1. É uma rede convolucional simples. Ela recebe a imagem de 128 × 128 × 1 e termina em 2 saídas com softmax, uma por classe. Quase todos os seus parâmetros ficam na camada densa, que recebe um vetor de 50.176 números.

CNN 2. Na CNN 2, a terceira convolução passa a ter 128 filtros e ganha um max pooling. Com isso, o vetor que entra na camada densa cai para 25.088 números, e o total de parâmetros cai para 1,70 milhão. Antes da saída, o Dropout desliga neurônios ao acaso durante o treino, para reduzir o overfitting. Para uma comparação justa, as duas CNNs usam a mesma semente, o otimizador Adam e 10 épocas, um número que cabe no tempo do Colab gratuito. As CNNs não usam peso por classe: com 74% de pneumonia no treino, elas tendem a apontar mais pneumonia, o que ajuda o recall da classe doente, mas pode gerar mais alarmes falsos. A trava do recall de NORMAL controla esse efeito na validação.

PCA + Random Forest. Aqui, cada imagem é reduzida a 64 × 64 pixels e vira uma linha com 4.096 colunas, uma por pixel. Um Pipeline padroniza as colunas, aplica o PCA (95% da informação) e treina um Random Forest com 300 árvores. Ele usa `class_weight='balanced'`, porque 74% das imagens de treino são de pneumonia: o peso maior na classe NORMAL evita que o modelo chame quase todos de doentes.

Regra de escolha. Primeiro, descartamos os modelos com recall de NORMAL abaixo de 0,80 na validação, ou seja, os que erram mais de 1 em cada 5 exames normais. Entre os que sobram, vence o de maior recall de PNEUMONIA. Se a diferença for de até 0,02 (cerca de 15 das 770 pneumonias da validação), consideramos empate, e vence o de maior recall de NORMAL. Se nenhum modelo passar da trava, vence o que chegar mais perto dela. O notebook aplica essa regra sozinho, antes de olhar o teste.

Comparação na validação. A tabela usa as 1.035 imagens de validação.

Modelo	Recall PNEUMONIA	Recall NORMAL	F1	Acurácia
CNN 1	0,984	0,921	0,979	0,968
CNN 2	0,978	0,951	0,980	0,971
PCA + RF	0,996	0,475	0,915	0,863

Pela regra de escolha, o modelo final é a CNN 2, com recall de 0,978 para PNEUMONIA e de 0,951 para NORMAL na validação. Os outros dois modelos tiveram recall de PNEUMONIA de 0,984 (CNN 1) e 0,996 (PCA + RF). A CNN 1 teve recall de PNEUMONIA um pouco maior, mas a diferença ficou dentro da margem de empate (0,02), e a CNN 2 errou menos os exames normais. O PCA + RF teve recall de PNEUMONIA maior, mas foi descartado por errar demais os exames normais (recall de NORMAL abaixo de 0,80).

3.4 Resultados e interpretação

Curvas de treino. Na CNN 1, a perda de validação foi mínima na época 4 e voltou a subir depois, um sinal de overfitting. Na CNN 2, a perda de validação não voltou a subir de forma clara, sem sinal forte de overfitting. Medida depois do treino, a acurácia de treino ficou 2,7 pontos acima da de validação na CNN 1 e 0,6 ponto na CNN 2. Quanto maior essa distância, mais a rede decorou o treino. As mudanças da CNN 2 (mais filtros, um pooling a mais e Dropout) reduziram essa distância.

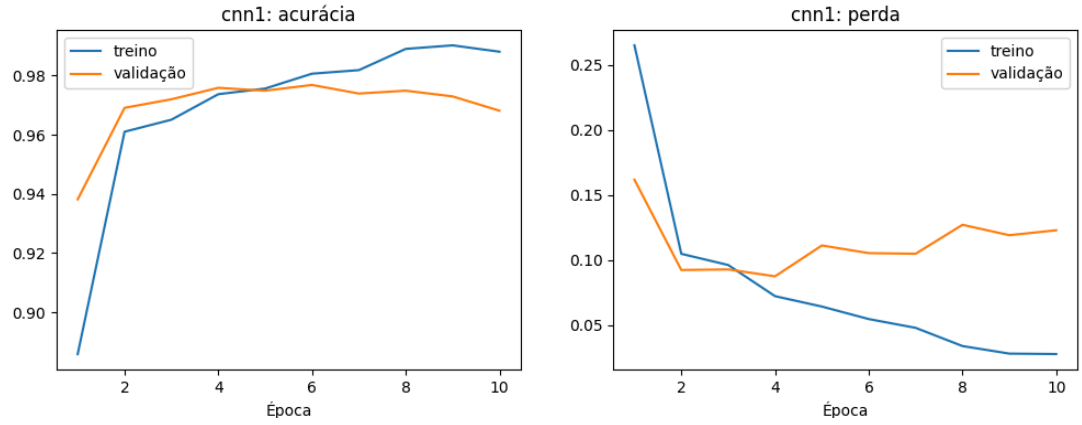


Figura 14 — CNN 1: acurácia e perda por época, no treino e na validação

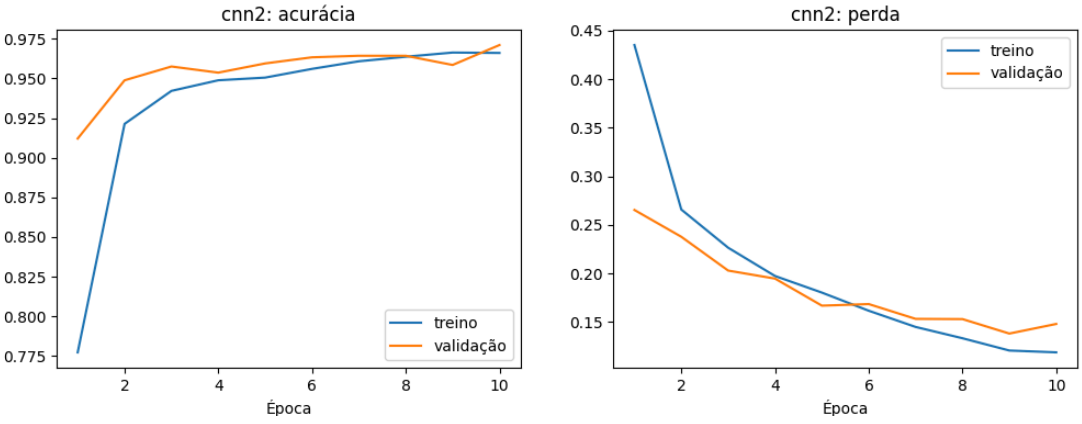


Figura 15 — CNN 2: acurácia e perda por época, no treino e na validação

Resultado no teste. No teste, com 624 imagens (234 NORMAL e 390 PNEUMONIA), a CNN 2 encontrou 385 das 390 pneumonias, um recall de 0,987. Deixou passar 5 casos, o erro mais grave neste problema. Entre os 234 exames normais, acertou 95 (recall de 0,406) e deu 139 alarmes falsos. A AUC foi de 0,896. O recall de NORMAL caiu de 0,951, na validação, para 0,406, no teste. Uma explicação provável: a validação vem da mesma pasta do treino, e o teste foi montado à parte. Por isso, a validação não mostrou essa queda. Para comparação, a CNN 1 deixou passar 1 pneumonia e o PCA + RF não deixou passar nenhuma pneumonia.

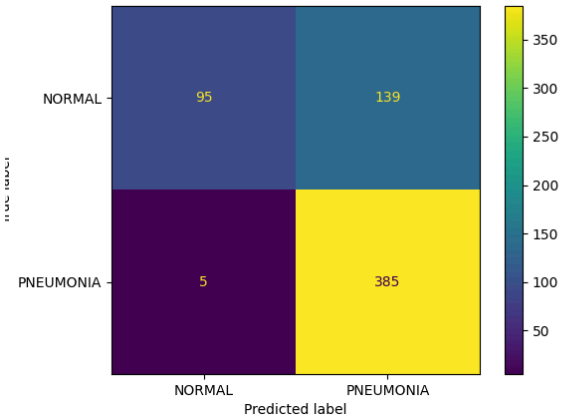


Figura 16 — Matriz de confusão do modelo final da Parte B no teste

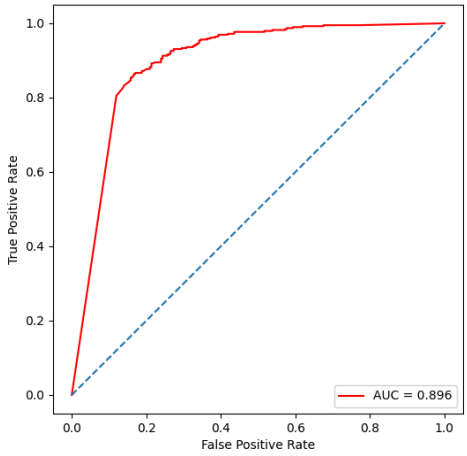


Figura 17 — Curva ROC do modelo final da Parte B no teste

Interpretação. Além da matriz de confusão, que mostra o tipo de erro, usamos três ferramentas. A grade de previsões mostra exemplos de acertos (em azul) e de erros (em vermelho). O mapa de oclusão (Zeiler e Fergus, 2014) mostra o que pesou na decisão: ele cobre um quadrado da imagem por vez e mede quanto a certeza de pneumonia cai. Como o SHAP da Parte A, ele explica uma imagem por vez; usamos a oclusão porque, com imagens, o SHAP é bem mais lento e difícil de ler. Por fim, medimos quanto do peso do mapa fica no centro da imagem, onde estão os pulmões.

Na matriz de confusão, há 5 falsos negativos e 139 falsos positivos. No mapa de oclusão, medido em 15 acertos de pneumonia, 53% do peso ficou na região central da imagem, que ocupa 56% da área. Ou seja, uma parte importante do peso está nas bordas, fora dos pulmões. O modelo pode estar usando pistas que não são a doença, como marcações do aparelho.

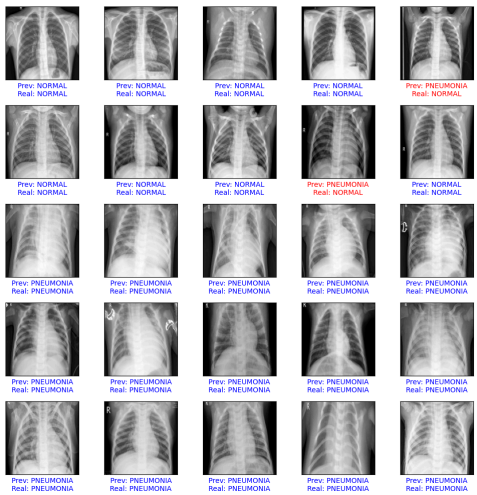


Figura 18 — Grade de 25 previsões do teste: azul é acerto, vermelho é erro

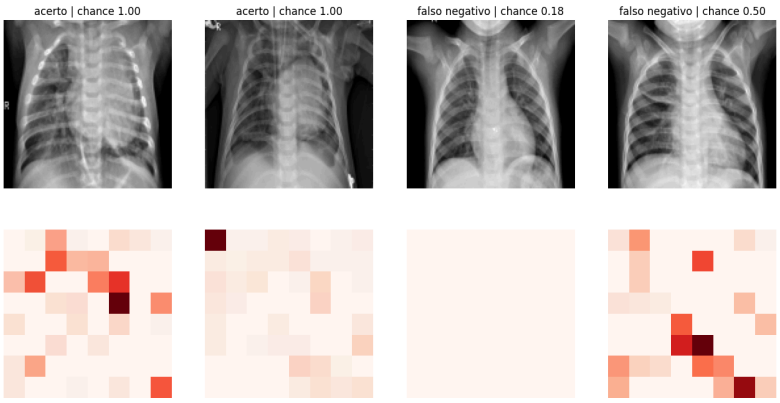


Figura 19 — Mapa de oclusão: raio-X em cima e o peso de cada quadrado embaixo

3.5 Discussão crítica

Limites. No teste, o modelo de imagens deixou passar 5 pneumonias das 390 e deu 139 alarmes falsos. A base tem só crianças de 1 a 5 anos, de um único hospital chinês, então o modelo não vale para adultos nem para outros aparelhos sem um novo teste. A validação foi separada por paciente, mas não previu a queda do recall de NORMAL no teste (seção 3.4). Por fim, as imagens foram reduzidas para 128 × 128 pixels, em cinza, e perdem detalhes que o médico enxerga.

Limiar de decisão. Como na Parte A, o modelo dá uma probabilidade, e o padrão é chamar de pneumonia quem passa de 0,5. A curva ROC mostra a mesma troca entre doentes perdidos e alarmes falsos. O limiar também deve ser escolhido com a equipe médica, usando dados de validação e nunca o teste.

Próximos passos. Testar o modelo com dados do próprio hospital, usar peso por classe e aumento de dados nas CNNs e parar o treino na melhor época.

Conclusão. A CNN 2 encontrou 99% das pneumonias do teste, mas o recall entre os exames normais foi de só 0,41. O modelo de imagens ainda dá alarmes falsos demais e precisa melhorar antes de qualquer uso.

4. Uso na prática

Os modelos servem para apoiar a triagem, e não para dar o diagnóstico. Hoje, só o da Parte A está perto disso; o da Parte B ainda dá alarmes falsos demais. Na prática, o modelo entra depois do exame e antes da consulta. Para cada exame, ele mostra a chance de doença e o que mais pesou na decisão (as colunas ou as áreas da imagem), e os casos acima do limiar sobem na fila do médico. Na Parte A, o limiar é baixo de propósito: basta uma chance de câncer de 9,7%. Um resultado "não doente" nunca dispensa o paciente: todos os exames continuam sendo vistos pelo médico, que tem a palavra final. O hospital também precisa acompanhar os erros do modelo ao longo do tempo e seguir as regras da Anvisa para software usado em saúde.

Referências

Bases de dados

- Wolberg, W.; Mangasarian, O.; Street, N.; Street, W. (1993). Breast Cancer Wisconsin (Diagnostic). UCI Machine Learning Repository. DOI 10.24432/C5DW2B. Versão usada: Kaggle.
- Kermany, D.; Zhang, K.; Goldbaum, M. (2018). Large Dataset of Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images. Mendeley Data, v2. DOI 10.17632/rscbjbr9sj.2. Versão usada: Chest X-Ray Images (Pneumonia), Kaggle, que copia a v2.

Artigos

- Kermany, D. et al. (2018). Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell*, 172(5), 1122–1131.e9. DOI 10.1016/j.cell.2018.02.010.
- Zeiler, M.; Fergus, R. (2014). Visualizing and Understanding Convolutional Networks. ECCV 2014, LNCS 8689, p. 818–833. Seção 4.2: teste de oclusão.
- Lundberg, S.; Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NIPS 2017 (Advances in Neural Information Processing Systems 30), p. 4765–4774. Artigo do SHAP.
- Srivastava, N. et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research*, 15(56), 1929–1958.
- TensorFlow. Convolutional Neural Network (CNN), tutorial oficial. https://www.tensorflow.org/tutorials/images/cnn